Détection d'Erreurs Iatrogéniques par Apprentissage Auto-Supervisé

Présenté par :
Albane Vial

Sous la direction de :
M. Hammadi

27 mars 2026

Abstract

L'iatrogénie médicamenteuse représente une préoccupation majeure dans le domaine médical. Ce projet explore l'apprentissage auto-supervisé pour détecter automatiquement les erreurs de prescription à partir de données textuelles issues de la base MIMIC-IV. L'approche repose sur la formulation du problème en détection d'anomalies en comparant l'architecture ELECTRA classique avec DeBERTaV3 (intégrant le mécanisme GDES).

Mots-clés : détection d'anomalies, modèles de langage, apprentissage auto-supervisé, ELECTRA, DeBERTaV3.

Contents

1 Contexte et problématique **2**

2 État de l'art des systèmes de détection **2**

3 Données et reformulation du problème **3**

4 Approches de détection d'anomalies **3**

5 Objectifs et tâches du projet **4**

6 Approche proposée : apprentissage auto-supervisé **5**

7 Analyse de la base de données **6**

8 Création du dataset de test **9**

9 Présentation et analyse des résultats **11**

9.1 Performance de détection binaire et robustesse 11
9.2 Sensibilité aux anomalies de dosage 11
9.3 Hétérogénéité de détection et analyse des biais de performance 12
9.4 Complexité des prescriptions multi-erreurs 13
9.5 Fiabilité contextuelle et hallucinations 14
9.6 comparaison avec l'état de l'art 14

10 Conclusion **14**

1 Contexte et problématique

L'iatrognéie est l'ensemble des effets indésirables provoqués par la prise d'un ou de plusieurs médicaments qu'ils soit lié soit par une surdose, une prise d'un médiacement contre indiqué pour une autre prise d'un médicament ou alors d'une erreur du moyen de prise du médicamment. Ces effets constituent une cause significative d'hospitalisations prolongées et de décès évitables. Les risques associés aux erreurs de prescriptionLes erreurs de prescription exposent les patients à des risques directs (réactions allergiques, interactions médicamenteuses dangereuses, toxicité) et sont extrêmement fréquentes dans la pratique hospitalière et ambulatoire.

- **Une prévalence élevée** : Les discordances entre la prescription théorique et l'administration physique au lit du patient sont massives. Une étude d'observation de terrain révèle que 65% des médicaments administrés présentent une non-conformité (NC) par rapport à l'ordonnance informatisée présente dans le logiciel. [1].

- **Les causes principales** : La grande majorité de ces non-conformités (86%) prend racine dans des erreurs de prescription initiale, qui se manifestent souvent par des ordonnances incomplètes ou l'omission de la saisie des traitements personnels préexistants du patient.[1]

- **La typologie des erreurs** : [3] Une étude met en évidence trois sources critiques et parfois cumulatives de défaillances. Les erreurs quantitatives liées au dosage (posologie) prédominent massivement, représentant jusqu'à 53% des anomalies dans certaines études. Suivent les erreurs de voie d'administration, impliquées dans 43% des cas. Enfin, les erreurs temporelles, qui incluent la fréquence des prises et la durée globale du traitement, concernent environ 28% des prescriptions erronées.

- **L'impact clinique** : Si l'impact clinique est nul dans 75% des cas, il est important de souligner que 10% de ces erreurs ont un impact clinique jugé préoccupant, incluant des risques vitaux nécessitant une intervention médicale.[1]

L'analyse systématique des prescriptions par un pharmacien est reconnue comme essentielle pour réduire ces risques. Cependant, elle se heurte en pratique à des contraintes de temps et de personnel qui limitent sa portée. Cette réalité justifie le développement d'outils automatiques d'aide à la détection des erreurs.

2 État de l'art des systèmes de détection

Les systèmes actuels de détection des erreurs de prescription se divisent en deux catégories majeures : les systèmes à base de règles cliniques et les systèmes basés sur l'apprentissage automatique.

- **Systèmes à base de règles cliniques :** Ces systèmes d'alerte reposent sur des règles fixées par des professionnels de santé. Ils codifient explicitement les connaissances médicales sous forme de règles (interactions connues, seuils

de dosage, contre-indications). Bien que robustes sur les cas référencés, ils ne couvrent pas les erreurs nouvelles ou atypiques. Cette méthode manque de souplesse vis-à-vis du contexte clinique spécifique du patient. En effet, d'après une étude, cette approche utilisée par les CDSS (*Clinical Decision Support Systems*) génère souvent une « fatigue des alertes » chez les praticiens en raison d'un taux de faux positifs élevé. Cette étude a mobilisé un pharmacien afin de filtrer les alertes et en a déduit que 75 % n'étaient pas pertinentes à signaler au médecin prescripteur [2].

- **Systèmes basés sur l'apprentissage automatique :** Ces systèmes sont plus flexibles et capables de capturer des motifs complexes. Cependant, ces méthodes doivent également satisfaire des contraintes critiques, notamment :
  - **Une transparence du modèle :** Étant donné que cette application est destinée à une exploitation en milieu médical, il est essentiel que le modèle soit transparent et doté d'une forte explicabilité.
  - **Une forte dépendance aux données privées et labellisées :** Les données médicales sont des données sensibles qui nécessitent une sécurité accrue et une anonymisation stricte des patients. Il est donc particulièrement difficile de constituer une base de données volumineuse, libre d'accès et correctement labellisée.

3 Données et reformulation du problème

La base de données publique MIMIC (*Medical Information Mart for Intensive Care*) constitue une ressource ouverte et reproductible pour la recherche en santé. Elle contient des données cliniques réelles de patients hospitalisés. Cette base de données comportent des informations complètes sur les patients mais aussi sur les prescritpions.Cependant, MIMIC ne recense que des prescriptions validées, il n'existe pas d'exemples d'erreurs étiquetées. Puisque MIMIC ne répertorie que les actes médicaux validés et administrés, elle ne contient par définition que des exemples "positifs" (des prescriptions considérées comme correctes par le corps médical à l'instant T). En l'absence d'exemples "négatifs" (des erreurs médicales avérées et étiquetées), il est mathématiquement impossible d'entraîner un algorithme de classification binaire supervisé classique (erreur vs non-erreur).

Ce constat transforme le problème en un problème de **generasition et détection d'anomalies** : il s'agit d'apprendre la distribution des prescriptions « normales » afin d'identifier les motifs qui s'en écartent de manière significative, sans supervision externe.

4 Approches de détection d'anomalies

Une étude récente, proposée par Ouzar et al. (2024) , a introduit une méthode de détection d'erreurs de prescription basée sur la classification à une classe (One-Class Classification). Cette architecture se décompose en trois étapes distinctes :

- **Encodage des données** : L'étude utilise des modèles de traitement du langage naturel, tels que Word2Vec et BERT, pour transformer les éléments textuels des prescriptions en vecteurs numériques. Les résultats démontrent que l'approche contextuelle de BERT est significativement plus performante.

- **Réduction de dimensionnalité** : Afin d'optimiser le traitement de ces vecteurs à haute dimension, des méthodes telles que l'Analyse en Composantes Principales (PCA) et les auto-encodeurs (AE) sont appliquées pour projeter les données dans un sous-espace réduit tout en conservant l'information essentielle.

- textbfModélisation par classification : Un algorithme non supervisé (tel que l'Isolation Forest ou le Local Outlier Factor) est entraîné pour modéliser les caractéristiques de la classe normale, permettant ainsi de détecter les prescriptions qui s'en écartent.

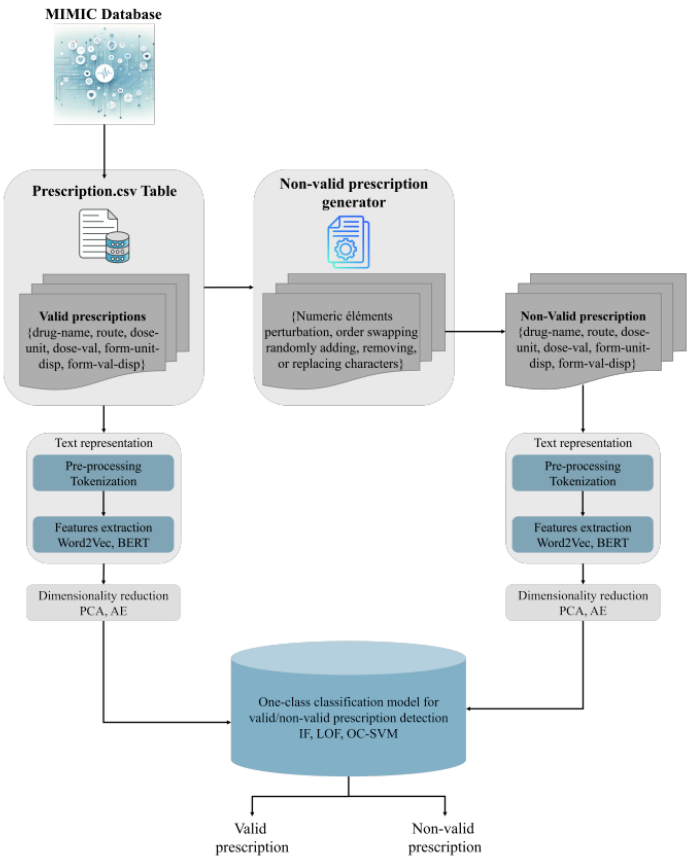

Figure 1: Enter Caption

5 Objectifs et tâches du projet

Les objectifs fixés pour ce projet sont les suivants:

1. **Étude bibliographique :** analyser les travaux existants sur l'apprentissage auto-supervisé appliqué au traitement du texte et à la détection d'anomalies.
2. **Représentations sémantiques :** explorer et évaluer des modèles de langage pré-entraînés pour encoder les données textuelles de prescription.
3. **Implémentation et évaluation :** implémenter les différentes architectures de détection d'anomalies et les comparer sur les données MIMIC.

6 Approche proposée : apprentissage auto-supervisé

Afin de modéliser les caractéristiques des prescriptions valides, notre travail propose d'explorer une approche auto-supervisée basée sur l'architecture DeBERTaV3. Cette architecture est basées sur:

- Replaced Token Detection - RTD: Ce sont des calculs de densité locale en exploitant la tâche de Détection de Tokens Remplacés
- Deux réseaux de neurones de type Transformer :
  - Un générateur : entraîné par modélisation de langage masquée (MLM), sa fonction est de remplacer certains mots masqués dans une prescription normale par des alternatives plausibles.
  - Un discriminateur : entraîné par maximum de vraisemblance, il doit déterminer pour chaque mot de la prescription s'il s'agit d'une donnée originale ou d'un remplacement artificiel.
- Un partage d'embeddings avec séparation des gradients (Gradient-Disentangled Embedding Sharing - GDES): Pour optimiser cet apprentissage, nous intégrerons . Dans une architecture classique, le partage des représentations vectorielles (embeddings) entre le générateur et le discriminateur crée un conflit d'optimisation. En effet, le générateur rapproche les mots sémantiquement proches, tandis que le discriminateur les éloigne pour mieux les distinguer. La méthode GDES résout ce problème en bloquant la rétropropagation du gradient du discriminateur vers les embeddings du générateur. Les représentations conservent ainsi leur cohérence sémantique tout en bénéficiant à la tâche de détection.

Dans le cadre de la détection d'anomalies, le modèle est entraîné exclusivement sur un corpus de prescriptions valides afin que le discriminateur assimile le contexte clinique normal.

En phase d'exploitation, lorsqu'une nouvelle prescription est soumise au modèle, tout élément s'écartant de la distribution normale apprise poussera le discriminateur à le classer comme un token "remplacé". Le score d'anomalie global de la prescription sera alors calculé en agrégeant les probabilités de remplacement prédites pour chaque élément textuel.

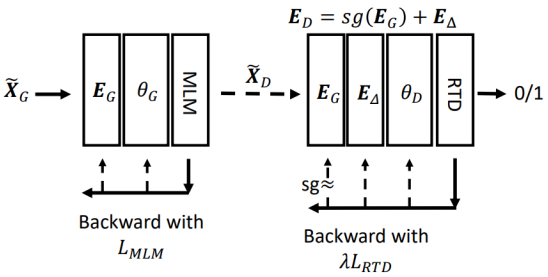

Figure 2: DebertaV3

7 Analyse de la base de données

Pour notre projet, nous avons extrait des données issues de 7 tables différentes de la base MIMIC-IV :

- **Diagnostics :** Jointure entre `diagnoses_icd` et `d_icd_diagnoses` pour obtenir les codes ICD et le nom complet de la maladie.
- **Démographie :** Extraction du genre et de l'âge (`anchor_age`) depuis la table `patients`.
- **Hospitalisation :** Récupération du type d'admission (`admission_type`) via la table `admissions`.
- **Traitements :** Extraction de la table `prescriptions` (molécule, dosage, voie d'administration).
- **Biologie :** Filtrage spécifique sur les identifiants d'examens (`itemid` pour la créatinine, le potassium, etc.) dans `labevents` avec une jointure sur `d_labitems`.

Après la jointure initiale de ces tables, nous avons recensé plus de 10 millions de prescriptions distinctes. Pour constituer un corpus d'apprentissage équilibré d'environ 200 000 prescriptions, nous avons appliqué plusieurs filtres stricts :

1. Filtrage par profil patient

Nous avons fait le choix de conserver uniquement les patients ayant reçu moins de 50 prescriptions au cours de leur séjour. Ce sous-ensemble représente environ 64 % de la base de données originale. Ce seuil garantit une plus grande diversité d'individus dans le jeu de données final, évitant que le modèle ne sur-apprenne les schémas atypiques d'une minorité de patients ultra-médicalisés.Cependant, cette restriction exclut de facto les profils cliniques les plus lourds (ex: longs séjours en soins intensifs). Le modèle risque donc de perdre en performance face à des situations réelles de polypharmacie complexe.

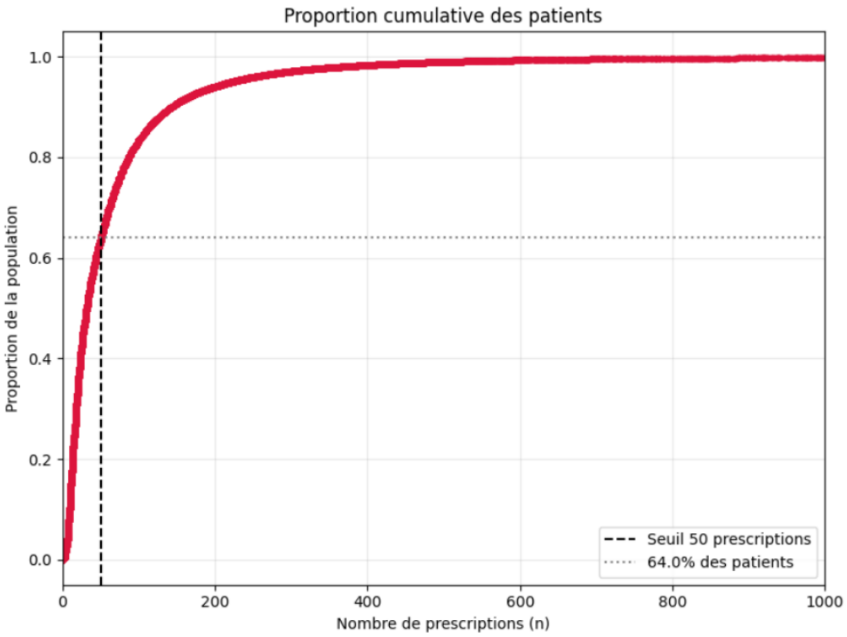

Figure 3: Courbe de la proportion cumulative des patients

2. Filtrage par fréquence des molécules

Nous avons restreint le corpus aux molécules comptabilisant plus de 500 prescriptions. Bien que ce filtre écarte les traitements rares, il permet de conserver 90 % du volume total des médicaments administrés, assurant ainsi une fréquence d'apparition suffisante pour que l'apprentissage auto-supervisé soit statistiquement viable.

3. Échantillonnage stratifié

Pour réduire le volume final aux 200 000 prescriptions ciblées tout en préservant la représentativité de la base, nous avons procédé à un échantillonnage stratifié basé sur la variable `drug` (médicament). Cette méthode garantit que la proportion de chaque molécule dans notre échantillon final reflète rigoureusement la distribution d'origine. Les médicaments situés juste au-dessus du seuil des 500 prescriptions ne risquent pas de disparaître par le simple hasard du tirage.

4. Nettoyage des valeurs aberrantes

Malgré la structuration de la base MIMIC-IV, certaines données de dosage s'avéraient cliniquement aberrantes (ex: dosages à 0 unité). Nous avons appliqué un filtre d'exclusion dynamique, supprimant les valeurs inférieures au 1er centile et supérieures au 99e centile pour chaque molécule.

Par ailleurs, l'analyse exploratoire souligne plusieurs défis pour la modélisation :

- **Pluralité des voies d'administration :** Un même médicament peut posséder plusieurs voies d'administration (Figure 4). Cette variance complexifie la

tâche du modèle, qui doit apprendre à distinguer une véritable erreur médicale d'une simple variation de pratique clinique valide.

- **Variance des dosages :** Nous observons que l'écart-type des doses pour la majorité des médicaments est relativement faible (Figure 5). Cette concentration statistique est un atout : elle facilitera la détection d'anomalies (sur/sous-dosages) par le modèle pour ces molécules spécifiques.

- **Hétérogénéité des unités de mesure :** Si la majorité des médicaments ne possède qu'une seule unité de mesure, les exceptions comportant des unités multiples (Figure 6) introduisent un risque de confusion sémantique. Pour traiter cette difficulté, notre modèle s'appuiera sur son mécanisme d'attention globale : au lieu d'utiliser des règles de conversion mathématiques strictes, l'architecture DeBERTa analysera le contexte entier de la phrase clinique pour déterminer si le couple dose/unité est cohérent pour la molécule donnée.

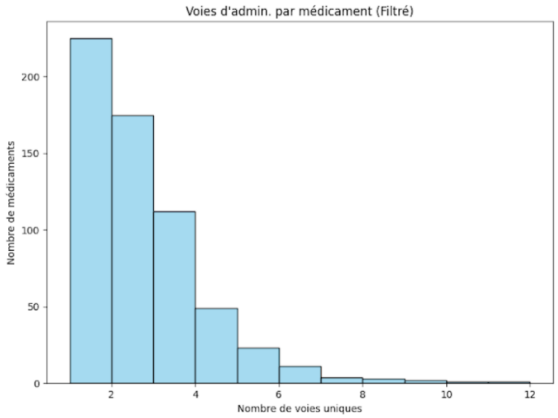

Figure 4: Distribution du nombre de voies d'administration par médicament

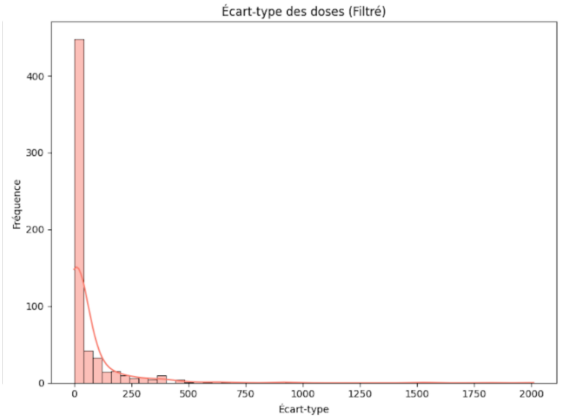

Figure 5: Distribution de l'écart-type des doses par médicament

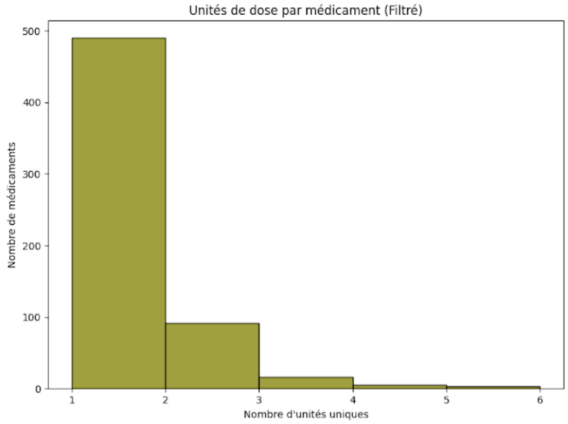

Figure 6: Distribution du nombre d'unités de dose par médicament

Afin de modéliser l'état du patient pour cette tâche, les variables tabulaires extraites de la base sont concaténées sous la forme d'une phrase clinique structurée par des balises sémantiques. Les caractéristiques retenues sont les suivantes :

- **Paramètres de la prescription :** La molécule administrée (`[DRUG]`), la valeur numérique du dosage (`[DOSE]`), son unité de mesure (`[UNIT]`), et la voie d'administration (`[ROUTE]`).
- **Profil administratif et démographique :** Le genre du patient (`[GEN]`) et le type d'admission hospitalière (`[ADM]`).
- **Contexte médical et physiologique :** L'historique des diagnostics codés (`[DX]`) ainsi que les résultats d'examens biologiques associés à un indicateur de normalité (`[BIO]`).

8 Création du dataset de test

Afin d'évaluer les performances de notre modèle de détection, il est impératif de disposer d'un jeu de données contenant des anomalies étiquetées. La base de données MIMIC-IV étant constituée de prescriptions cliniquement validées, nous avons mis en place un protocole de génération synthétique d'erreurs. Ce processus vise à introduire des dégradations contrôlées au sein de prescriptions initialement correctes.

Typologie des erreurs générées

Notre algorithme de perturbation génère artificiellement cinq catégories distinctes d'anomalies, ciblant les différentes composantes de la phrase clinique :

- **Erreur de molécule (`drug`) :** Altération typographique du nom du médicament par insertion, suppression ou substitution aléatoire d'un caractère.
- **Erreur de voie d'administration (`route`) :** Remplacement de la voie d'administration originelle par une autre voie tirée aléatoirement parmi l'ensemble des voies disponibles dans la base.

- **Erreur d'unité (`unit`) :** Substitution de l'unité de dosage par une unité discordante.
- **Sous-dosage et Sur-dosage (`dose_val_rx`) :** Modification de la valeur numérique de la dose prescrite. Ces valeurs aberrantes sont calculées de manière statistique pour chaque médicament, en soustrayant (sous-dosage) ou en additionnant (sur-dosage) un multiple de l'écart-type à la dose moyenne prescrite.

Stratégies d'évaluation : magnitude et multiplicité

Pour analyser finement le comportement et les limites de notre modèle, nous avons décliné la génération des données de test selon deux axes :

1. **Variation de la magnitude des erreurs de dosage :** Nous avons fait varier le paramètre multiplicateur de l'écart-type lors de la génération des anomalies quantitatives. Cela permet de générer des jeux de données avec des erreurs de dosage de différentes envergures, afin d'évaluer le seuil de sensibilité du modèle face à des déviations cliniques légères ou extrêmes.
2. **Cumul d'anomalies :** En plus d'un jeu de test contenant exclusivement des prescriptions comportant une unique erreur (*Single Error Dataset*), nous avons développé une fonction permettant d'injecter plusieurs types d'erreurs simultanées sur une même ligne de prescription (*Multiple Errors Dataset*). L'objectif est de vérifier la robustesse des représentations face à un signal fortement bruité.

Partitionnement et composition du jeu d'évaluation

Pour garantir la validité de l'évaluation et éviter toute fuite de données (*data leakage*), la séparation du jeu de données a été effectuée avant la phase de génération des anomalies. Le corpus nettoyé a été divisé en un ensemble d'entraînement (90 %) et un ensemble de test (10 %).

Le jeu de test final comprend un total de 31 597 prescriptions.Nous avons structuré cet ensemble selon un ratio asymétrique :

- **Données saines (70 %) :** Un échantillon de prescriptions intactes, non modifiées par notre algorithme de perturbation, servant de référence de normalité.
- **Données anomaliques (30 %) :** Des prescriptions intentionnellement bruitées, extraites du reste du jeu de test initial.

Ce quota d'anomalies de 30 % a ensuite été subdivisé en deux proportions égales pour tester différents scénarios d'erreurs: les erreurs simples (avec une seule erreur dans la prescription) et les erreurs multiples (avec deux erreurs dans la prescription).

Bien qu'un taux d'anomalies de 30 % soit statistiquement supérieur à la prévalence réelle des erreurs médicamenteuses en milieu hospitalier, ce déséquilibre contrôlé est nécessaire pour garantir un volume suffisant d'exemples positifs, permettant ainsi de calculer des métriques d'évaluation robustes (Précision, Rappel).

Comparaison avec l'état de l'art

Dans le but de situer nos performances, nous avons entrepris une comparaison avec les résultats obtenus par l'étude d'Ouzar et al. sur la détection d'anomalies de prescription.

Toutefois, nous observons des divergences dans les métriques de performance. Ces différences s'expliquent par deux limitations méthodologiques incompressibles dans notre protocole de comparaison : d'une part, l'inaccessibilité du code source et des poids du modèle pré-entraîné de l'étude d'Ouzar, et d'autre part, l'utilisation de jeux de données de test fondamentalement distincts, les protocoles de génération synthétique d'erreurs n'étant pas strictement identiques. Par conséquent, les écarts de performance reflètent en partie des différences de complexité dans les données de test plutôt qu'une stricte supériorité ou infériorité architecturale.

9 Présentation et analyse des résultats

L'évaluation du modèle DeBERTaV3 repose sur sa capacité à discriminer les prescriptions saines des anomalies synthétiques. Pour les variables quantitatives, la perturbation est définie par la fonction $f(dose) = \mu \pm p \cdot \sigma$, où μ représente la dose moyenne et σ l'écart-type de la molécule concernée. L'analyse explore l'impact de ce facteur de sévérité p sur la robustesse du modèle.

9.1 Performance de détection binaire et robustesse

Le modèle démontre une stabilité remarquable malgré la variation de p. La précision se maintient à un niveau quasi constant (environ 0,993), ce qui indique une très faible propension du modèle à générer des faux positifs, quelle que soit l'ampleur de l'erreur de dosage injectée

Table 1: Synthèse des performances globales selon le facteur de perturbation p

Coefficient de perturbation (p)	**0.2**	**0.5**	**1.0**	**2.0**
Exactitude (Accuracy)	0,9200	0,9146	0,9164	0,9187
Précision	0,9935	0,9933	0,9934	0,9934
Rappel (Recall)	0,7380	0,7201	0,7261	0,7339
F1-Score	0,8469	0,8349	0,8389	0,8442

9.2 Sensibilité aux anomalies de dosage

L'analyse de la classe `dosage` permet d'évaluer la finesse sémantique du modèle. Bien que le taux de détection progresse avec l'augmentation de la perturbation (passant de 66,79 % à 68,47 %), cette évolution reste marginale. Cela indique que le modèle identifie la rupture de cohérence contextuelle sans pour autant posséder une "échelle numérique" interne parfaite. La difficulté à dépasser le seuil des 70 % de détection souligne la limite des modèles de langage pour traiter des variables continues.

Table 2: Évolution de la détection des anomalies de dosage selon la magnitude (p)

Magnitude de perturbation (p)	**0.2**	**0.5**	**1.0**	**2.0**
Total cas réels (1 erreur)	536	536	536	536
Total détectés (1 erreur)	358	363	356	367
Taux de détection (%)	**66,79 %**	**67,72 %**	**66,42 %**	**68,47 %**
Précision de la classe	0,97	0,97	0,97	0,98
F1-score de la classe	0,76	0,75	0,75	0,77

9.3 Hétérogénéité de détection et analyse des biais de performance

L'analyse granulaire des résultats révèle une disparité flagrante dans la capacité du modèle à identifier les différentes catégories d'anomalie. Cette asymétrie de performance permet de distinguer les domaines où l'apprentissage auto-supervisé excelle de ceux où il rencontre des limites structurelles ou méthodologiques.

Table 3: Taux de détection par catégorie (pour $p = 2$, erreur unique)

Catégorie d'erreur	**Taux de détection (%)**
Molécule (`drug`)	97,38 %
Dosage (`dosage`)	68,47 %
Unité (`unit_dosage`)	41,57 %
Voie (`route`)	27,61 %

L'interprétation de ces variations met en évidence plusieurs facteurs explicatifs :

- **Maîtrise sémantique des molécules** : Le taux de détection quasi parfait sur la classe `drug` démontre que le modèle a assimilé les associations cliniques . DeBERTaV3 identifie avec une grande précision lorsqu'un médicament n'est pas cohérent avec le reste de la phrase . Toutefois, cette performance doit être nuancée par la nature de la perturbation : l'erreur de type `drug` reposant sur des fautes de frappe (altérations typographiques), elle crée un signal visuel et syntaxique très fort que le discriminateur isole avec facilité.

- **Sensibilité numérique modérée** : Pour le `dosage`, le modèle affiche une sensibilité correcte mais plafonnée à 68,47 % . Il détecte la rupture de cohérence provoquée par une valeur statistiquement aberrante, sans toutefois posséder une compréhension arithmétique fine des grandeurs. Le plafonnement suggère que le modèle traite le nombre comme un symbole textuel plutôt que comme une mesure physique.

- **Faiblesse sur les protocoles d'administration** : Les catégories `unit_dosage` et `route` affichent les résultats les plus bas, respectivement 41,57 % et 27,61 % . Cette difficulté à lier l'unité ou la voie au couple médicament/dose souligne une compréhension encore superficielle des modalités logistiques de la prescription .

Analyse des biais méthodologiques (Classes `route` et `unit_dosage`) : Il est crucial de souligner que les performances particulièrement faibles sur ces deux catégories peuvent être en partie imputées à un déséquilibre méthodologique lors de la création du jeu de données de test. Pour les catégories `route` et `unit_dosage`, la substitution a été effectuée par un tirage aléatoire parmi l'ensemble des valeurs disponibles dans la base MIMIC-IV, sans restriction aux options cliniquement incompatibles pour une molécule spécifique.

Ce protocole a mécaniquement généré des "erreurs" qui correspondent en réalité à des pratiques cliniques valides (par exemple, remplacer une voie orale par une voie intraveineuse pour un médicament supportant les deux). Ces anomalies, étant statistiquement plausibles dans le corpus d'entraînement, deviennent indétectables pour un modèle cherchant à identifier des ruptures de distribution. Un affinement de l'algorithme de perturbation, s'appuyant sur un référentiel strict des couples autorisés, permettrait d'évaluer plus justement la sensibilité réelle du discriminateur.

9.4 Complexité des prescriptions multi-erreurs

Le passage d'une erreur unique à un cumul d'anomalies au sein d'une même phrase clinique révèle une saturation du mécanisme d'attention du modèle. Si DeBERTaV3 conserve une excellente capacité à signaler qu'une prescription est globalement erronée, sa précision de diagnostic fin (capacité à identifier l'intégralité des sources d'erreurs) s'effondre lors du cumul de fautes.

Le tableau suivant illustre ce différentiel de performance pour un facteur de perturbation $p = 2$:

Table 4: Comparaison des capacités de caractérisation (Perturbation $p = 2$)

Métrique	**1 erreur (Single)**	**2 erreurs (Multiple)**
Volume de l'échantillon (TP)	839	1125
Match Strict (Diagnostic exact)	**88,56 %**	**27,38 %**
Match Partiel (Au moins une erreur trouvée)	96,78 %	99,20 %
Rappel Moyen	96,78 %	65,07 %

- **Robustesse de la détection binaire** : La métrique *Match Partiel* reste extrêmement élevée, voire progresse légèrement (99,20 %) . Cela signifie que plus une prescription est corrompue, plus le modèle est certain de son caractère anormal.

- **Effondrement du diagnostic précis** : La chute drastique du *Match Strict* (de 88,56 % à 27,38 %) démontre que le modèle échoue à isoler simultanément tous les tokens corrompus.

- **Mécanisme de masquage attentionnel** : Ce phénomène s'explique par la nature du discriminateur. Une fois qu'un token est identifié comme "remplacé" avec une forte probabilité, l'influence des tokens voisins également corrompus peut être masquée. Le signal d'anomalie dominant sature l'attention, empêchant une caractérisation exhaustive de la prescription.

9.5 Fiabilité contextuelle et hallucinations

L'introduction de la classe `autre` pour surveiller les sections non liées à la prescription (biologie, diagnostics, démographie) valide la spécificité du système. Le volume extrêmement faible d'hallucinations (0,03 %) prouve que le modèle ne "sur-détecte" pas d'erreurs dans le contexte clinique global, ce qui est crucial pour limiter la fatigue des alertes en milieu hospitalier.

Table 5: Analyse des hallucinations (Classe `autre`)

Métrique	**Valeur mesurée**
Volume de prédictions erronées sur `autre`	3 cas
Proportion sur le jeu de test	0,03 %
Impact sur la précision globale	Négligeable

9.6 comparaison avec l'état de l'art

Pour situer les performances du modèle, nous les comparons aux résultats rapportés par Ouzar et al. utilisant des méthodes de classification à une classe (OCC) sur des embeddings BERT réduits par PCA.

Table 6: Comparaison des performances globales (DeBERTaV3 vs Étude Ouzar)

Méthode	**Précision (%)**	**Rappel (%)**	**F1-Score (%)**
DeBERTaV3	**99,34 %**	73,39 %	84,42 %
PCA-LOF (Étude Ouzar)	81,71 %	**87,32 %**	**86,84 %**
PCA-Isolation Forest (Étude Ouzar)	73,91 %	65,40 %	68,79 %

Analyse critique : Notre modèle affiche une précision quasi-parfaite (99,34 %) , surpassant nettement le meilleur résultat d'Ouzar (81,71 % pour PCA-LOF). Cela indique une très faible propension du modèle à générer des faux positifs (seulement 13 cas sur plus de 6200 prescriptions saines) . En revanche, le rappel de l'étude Ouzar reste supérieur (87,32 % contre 73,39 %), ce qui suggère que leur approche capture une plus grande diversité d'erreurs, bien qu'au prix d'un taux de fausses alertes plus élevé.

10 Conclusion

Ce projet a permis de démontrer le potentiel de l'apprentissage auto-supervisé, et plus particulièrement de l'architecture DeBERTaV3, pour la détection d'anomalies iatrogéniques dans un contexte où les données étiquetées sont inexistantes.

L'approche par détection de tokens remplacés (RTD) s'est révélée particulièrement robuste pour identifier des erreurs sur les molécules elles-mêmes, affichant des taux de détection supérieurs à 97 %. Cependant, l'analyse des résultats nuance cette performance : le modèle peine encore à modéliser la finesse des paramètres d'administration (voies et unités) et la multiplicité des erreurs simultanées, qui saturent son mécanisme d'attention.

- **Comparaison avec l'état de l'art** : Une confrontation directe avec les résultats de l'étude d'Ouzar et al. (2024) a été entreprise. Toutefois, il est important de noter que nous n'avons pas réussi à reproduire les scores de performance exacts mentionnés dans leur article. Cette divergence s'explique par des limites méthodologiques majeures : l'inaccessibilité du code source original et des poids du modèle pré-entraîné, ainsi que l'utilisation de jeux de données de test fondamentalement distincts. Les protocoles de génération synthétique d'erreurs variant d'une étude à l'autre, la comparaison reste purement indicative.

- **Défis de l'intégration des diagnostics** : L'ajout des codes de diagnostic (`[DX]`) représente une piste d'amélioration évidente pour détecter des contre-indications. Cependant, la granularité extrême des codes ICD dans MIMIC-IV pose un défi de sparsité. Sans un nettoyage massif et un regroupement sémantique (par exemple via des ontologies médicales), cette information risque d'introduire un bruit tel qu'il pourrait "noyer" le signal de la prescription et dégrader la précision globale du modèle.

- **Perspective de la polypharmacie** : L'intégration d'autres prescriptions concomitantes pour un même patient permettrait de détecter des interactions médicamenteuses. La problématique réside alors dans la sélection : quelles prescriptions intégrer sans surcharger la fenêtre contextuelle du modèle ? Un ajout non sélectif risquerait de rendre l'apprentissage instable et d'augmenter drastiquement le temps de calcul.

En conclusion, si DeBERTaV3 constitue une avancée solide par rapport aux systèmes experts rigides, son déploiement clinique nécessite encore l'intégration de connaissances médicales structurées (graphes de connaissances) pour pallier l'absence de raisonnement clinique pur sur les variables numériques et les antécédents complexes.

References

[1] Malbranche, A. *La sécurisation par l'informatisation des prescriptions : les médicaments administrés sont-ils ceux prescrits* . Le Pharmacien Hospitalier et Clinicien, 2015.

[2] Cuvelier, *The clinical pharmacist's role in enhancing the relevance of a clinical decision support system* . International Journal of Medical Informatics , 2022.

[3] *Interpretable One-Class Classification Framework for Prescription Error Detection Using BERT Embeddings and Dimensionality Reduction.* International Journal of Medical Informatics, 2024.